TECHNICKÁ UNIVERZITA V LIBERCI
Fakulta mechatroniky, informatiky
a mezioborových studií

Vyhledávání vzorů

František Kynych
28. 11. 2024 | MVD

Část I.:
Úvod do problematiky

Vyhledávání vzorů

Proces automatického rozpoznání vzorů a pravidelností v datech

Co je to vzor?

- Množina prvků, dílčích sekvencí nebo podstruktur, které se v datech často vyskytují společně (silně korelované).

- Vzory často reprezentují vnitřní a důležité vlastnosti dat

Příklady

- Opakující se sekvence v textu, časté nákupní košíky v e-commerce, struktury v genetických datech.

Vyhledávání vzorů

Význam ve vytěžování dat

- Vytěžování vzorů
- Analýza kauzality
- Analýza vzorů v multimédiích, časových řadách a datových proudech

- Klasifikace
- Shlukování
- Prediktivní modelování
- Detekce anomálií

Praktické aplikace

- Které produkty jsou často společně zakoupeny
- Co dalšího lidé kupují po zakoupení určitého produktu
- Analýza trhu
- Analýza kódu a logů
- Detekce frází
- Detekce silně korelovaných úseků v časových řadách (biologická data, finance, …)

Vyhledávání vzorů je klíčovým krokem v analýze dat, který umožňuje odhalit skryté informace a podporuje rozhodovací procesy v různých oblastech.

Časté vzory (Frequent patterns)

- **Itemset**
  - Množina jedné nebo více položek
- **k-itemset**: $X = \{x_1, \ldots, x_k\}$
- **Absolutní support**, X
  - Počet transakcí obsahujících konkrétní itemset X
  - Např. pro {káva} = 3
- **Relativní support**, s
  - Podíl transakcí obsahujících itemset X vzhledem k celkovému počtu transakcí.
  - Pravděpodobnost, že bude transakce obsahovat položku X
  - Pro {káva} = $\frac{3}{5} = 60\ \%$
  - Itemset je častý (frequent), pokud je **relativní support** s vyšší než námi daný práh (**minsup**, označován také jako σ)

ID	Zakoupené položky
1	Káva, čaj, mléko
2	Káva, vajíčka, mléko
3	Káva, mléko, maso
4	Čaj, maso, pečivo
5	Čaj, vajíčka, mléko, maso, pečivo

Časté vzory (Frequent patterns)

Příklad: minsup = 50 %

- Hledáme množiny s hodnotou $s > 50\ \%$

Častý 1-itemset:

- Mléko: 4/5 (80 %)
- Káva: 3/5 (60 %); čaj: 3/5 (60 %); maso: 3/5 (60 %)

Častý 2-itemset:

- {Káva, mléko}: 3 (60 %)

ID	Zakoupené položky
1	Káva, čaj, mléko
2	Káva, vajíčka, mléko
3	Káva, mléko, maso
4	Čaj, maso, pečivo
5	Čaj, vajíčka, mléko, maso, pečivo

Asociační pravidla

- Asociační pravidla: $X \rightarrow Y(s, c)$
  - Pokud uživatel koupí položku X, jaký je support (s) a jistota (confidence, c), že uživatel koupí položku Y.
  - **Support** (s)
    - Pravděpodobnost, že transakce obsahuje zároveň položky X a Y ($X \cup Y$)
    - Poznámka: U itemsetu se značí obsažení obou položek zároveň sjednocením, nikoliv průnikem.
  - **Confidence** (c)
    - Podmíněná pravděpodobnost, že transakce obsahující X obsahuje i Y
    - $c = \frac{\sup(X \cup Y)}{\sup(X)}$
  - Těžení dat pomocí asociačních pravidel
    - Snažíme se najít všechny pravidla $X \rightarrow Y$ s parametry **minsup** a **minconf**

Asociační pravidla

Příklad: **minsup = 50 %**

Častý 1-itemset:

- mléko: 4, káva: 3, čaj: 3, maso: 3

Častý 2-itemset:

- {káva, mléko}: 3 (60 %)

minconf = 50 %

Asociační pravidla: $X \rightarrow Y(s, c)$

$$c = \frac{\sup(X \cup Y)}{\sup(X)}$$

$$c = \frac{\sup(káva \cup mléko)}{\sup(káva)} = \frac{3}{3} = 100\ \%$$

$káva \rightarrow mléko(60\ \%, 100\ \%)$;

$mléko \rightarrow káva(60\ \%, 75\ \%)$

Zakoupené položky
Káva, čaj, mléko
Káva, vajíčka, mléko
Káva, mléko, maso
Čaj, maso, pečivo
Čaj, vajíčka, mléko, maso, pečivo

Reprezentace vzorů

- Kolik častých vzorů obsahuje databáze TDB_1?
  - TDB_1: T_1:{a_1, …, a_{50}}; T_2: {a_1, …, a_{100}}
  - Předpokládaný minsup = 1
  - Výsledek:

    1-itemsets: {a_1}: 2, …, {a_{50}}: 2, {a_{51}}: 1, …, {a_{100}}: 1

    2-itemsets: {a_1, a_2}: 2, …, {a_1, a_{50}}: 2, {a_1, a_{51}}: 1, …, {a_{99}, a_{100}}: 1

    …

    99-itemsets: {a_1, a_2, …, a_{99}}: 1, {a_2, a_3, …, a_{100}}: 1

    100-itemsets: {a_1, a_2, …, a_{100}}: 1
  - Celkem $\binom{100}{1} + \binom{100}{2} + \ldots + \binom{100}{100} = 2^{100} - 1$ vzorů
  - Složité na výpočet i uložení

Reprezentace vzorů - komprese

- **Uzavřené vzory (closed patterns)**
  - Vzor (itemset) X je uzavřený, pokud X je častý vzor a neexistuje žádný super-vzor (nadmnožina) $Y \supset X$ se stejnou support hodnotou jako X

Příklad:

- TDB_1: T_1:{a_1, …, a_{50}}; T_2: {a_1, …, a_{100}}
- Předpokládaný minsup = 1
- TDB_1 nyní obsahuje pouze dva **uzavřené** vzory
  - P_1: {a_1, …, a_{50}}: 2
  - P_2: {a_1, …, a_{100}}: 1

- Bezeztrátová komprese
  - Stále dokážeme určit např. {a_2, …, a_{40}}: 2

Reprezentace vzorů - komprese

- **Maximální vzory (max-patterns)**
  - Vzor X je maximální, pokud X je častý vzor a neexistuje žádný super-vzor (nadmnožina) $Y \supset X$
  - Rozdíl oproti uzavřenému vzoru:
    - Nebereme ohled na support hodnotu

Příklad:

- TDB_1: T_1:{a_1, …, a_{50}}; T_2: {a_1, …, a_{100}}
- Předpokládaný minsup = 1
- TDB_1 nyní obsahuje pouze jeden **maximální** vzor
  - P: {a_1, …, a_{100}}: 1

- Ztrátová komprese
  - Víme, že vzor {a_2, …, a_{40}} je častý, ale neznáme support hodnotu

Část II.:
Základní přístupy vyhledávání vzorů

Apriori algoritmus

Využívá apriori principu

- Každá podmnožina častého vzoru (itemsetu) musí být také častá

Algoritmus:

1. Projít databázi a najít časté 1-itemsety (k=1)
   - Identifikovat jednotlivé položky splňující minsup.
2. Opakovat:
   1) Vygenerovat všechny možné (k+1)-itemsety (kandidáty)
   2) Otestovat vygenerované kandidáty v databázi:
      - Spočítat support.
      - Vyřadit ty, které nesplňují minsup.
   3) Inkrementovat k
   - Pokračovat, dokud není možné generovat další kandidáty.
3. Navrátit nalezené časté itemsety.

Apriori algoritmus

Databáze

ID	Položky
1	A, C, D
2	B, C, E
3	A, B, C, E
4	B, E

minsup = 2

1. kontrola DB

Itemset	Sup
{A}	2
{B}	3
{C}	3
{D}	1
{E}	3

F_1

Itemset	Sup
{A}	2
{B}	3
{C}	3
{E}	3

Generování kandidátů

Itemset
{A, B}
{A, C}
{A, E}
{B, C}
{B, E}
{C, E}

2. kontrola DB

Itemset	Sup
{A, B}	1
{A, C}	2
{A, E}	1
{B, C}	2
{B, E}	3
{C, E}	2

F_2

Itemset	Sup
{A, C}	2
{B, C}	2
{B, E}	3
{C, E}	2

Gen. kandidátů

Itemset
{B, C, E}

3. kontrola DB

F_3

Itemset	Sup
{B, C, E}	2

- Navrátit $F_1 \cup F_2 \cup F_3$

Apriori algoritmus

Výhody

- Jednoduchost a přehledná implementace.
- Efektivní pro menší databáze.

Nevýhody

- Výpočetně náročný při velkém počtu položek (velké kandidátní množiny).
- Prohledávání celé databáze opakovaně.

FPGrowth

Frequent pattern growth (FPGrowth)

- Řeší nedostatky Aprirori algoritmu:
  - **Apriori**: Opakovaně prochází databázi pro získání support hodnot.
  - **FP-Growth**: Není potřeba vytvářet list kandidátů.

- Prochází databázi pouze dvakrát s využitím stromové struktury (FP-tree) pro uložení informací.
- Po vytvoření stromu se využívá **divide-and-conquer** přístup pro vytěžení častých vzorů.

FPGrowth

Algoritmus:

1. Seřazení položek
   - V každé transakci podle jejich support hodnoty (sestupně)
2. Vytvoření FP-stromu
   - Na základě seřazených položek a jejich výskytu
3. FP-podmíněné stromy (FP-conditional tree):
   - Vytvoření pro každou položku (nebo itemset)
4. Nalezení častých vzorů
   - Kombinace jednotlivých položek z FP-stromu

FP-tree

ID	Položky v transakcích	Seřazené časté položky
1	{f, a, c, d, g, i, m, p}	{f, c, a, m, p}
2	{a, b, c, f, l, m, o}	{f, c, a, b, m}
3	{b, f, h, j, o, w}	{f, b}
4	{b, c, k, s, p}	{c, b, p}
5	{a, f, c, e, l, p, m, n}	{f, c, a, m, p}

Položka	Sup	Pointer
f	4	
c	4	
a	3	
b	3	
m	3	
p	3	

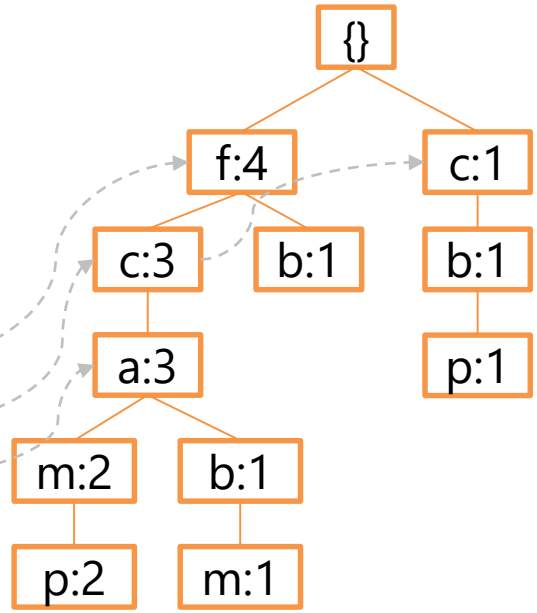

1. Projití DB a nalezení častých položek
   minsup = 3
   Výsledek **f: 4, a: 3, c: 4, b: 3, m: 3, p: 3**
2. Seřazení položek dle jejich frekvence
   F-list = f-c-a-b-m-p
3. Procházíme znovu databázi
   a vytváříme FP-strom

- Pointer ukazuje na první prvek v linked listu

FP-conditional tree

minsup = 3

Položka	Sup	Pointer
f	4	
c	4	
a	3	
b	3	
m	3	
p	3	

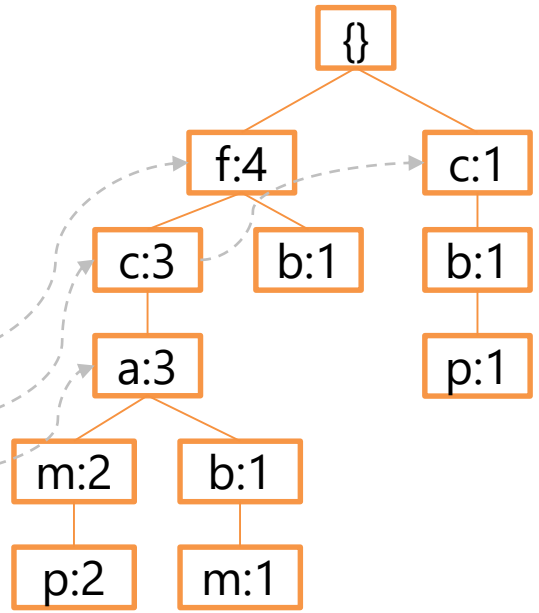

Položka	Conditional pattern base
c	f:3
a	fc:3
b	fca:1, f:1, c:1
m	fca:2, fcab:1
p	fcam:2, cb:1

- Obsahuje prefixové cesty položek

FP-conditional tree

Položka	Conditional pattern base
c	f:3
a	fc:3
b	fca:1, f:1, c:1
m	fca:2, fcab:1
p	fcam:2, cb:1

minsup = 3

Zbývá vytěžit data z conditional pattern base

- p-conditional PB: $\boldsymbol{fcam}$: **2**, $\boldsymbol{cb}$: **1** → $\boldsymbol{c}$: **3**
- m-conditional PB: $\boldsymbol{fca}$: **2**, $\boldsymbol{fcab}$: **1** → $\boldsymbol{fca}$: **3**
- b-conditional PB: $\boldsymbol{fca}$: **1**, $\boldsymbol{f}$: **1**, $\boldsymbol{c}$: **1** → ∅

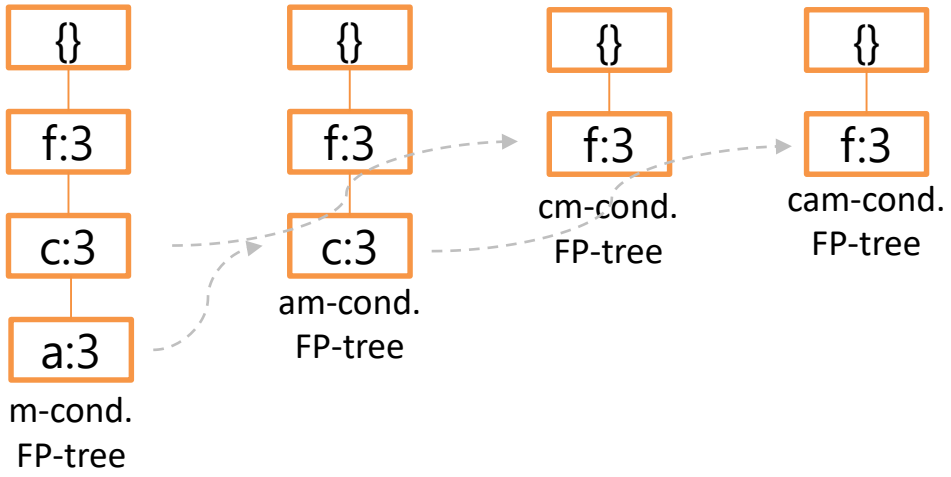

m: 3
fm: 3, cm: 3, am: 3
fcm: 3, fam: 3, cam: 3
fcam: 3

Těžení víceúrovňových častých vzorů

- Produkty často tvoří hierarchie
  - Např. hlavní kategorie mléko
  - Dále se dělí na jednotlivé značky a druhy
- Jak nastavit minsup parametr:
  - Uniformní minsup přes všechny úrovně
  - Redukovaný support v závislosti na úrovni

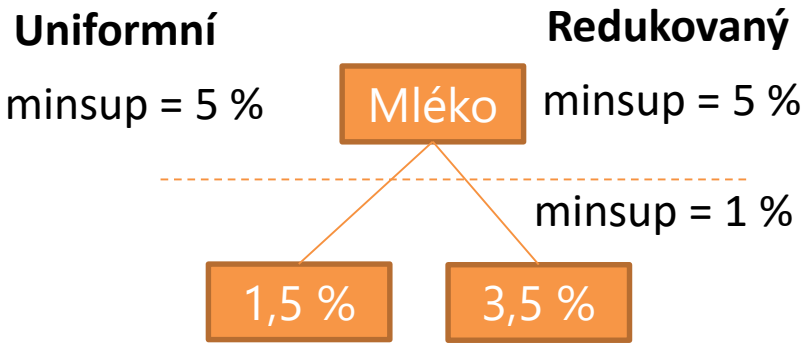

- V praxi je potřeba nastavit různou hodnotu minsup pro odlišné kategorie
  - Drahé produkty se neprodávají tak často, ale mohou mít velký přínos k příjmu

Těžení sekvenčních častých vzorů

- Sekvenční databáze obsahuje seřazené položky v závislosti na pořadí jejich zakoupení
- Aplikace:
  - Nákupy zákazníků (telefon, obal -> kabel -> sklo)
  - Biologické signály, přírodní katastrofy (zemětřesení)
  - DNA sekvence
  - Akcie a trhy

SID	Sekvence
1	<a(abc)(ac)d(cf)>
2	<(ad)c(bc)(ae)>
3	<(ef)(ab)(df)cb>
4	<eg(af)cbc>

a, (abc), (ac), … jsou jednotlivé transakce
<a(bc)dc> je subsekvence <**a**(a**bc**)(ac)**d**(**c**f)>

minsup = 2
<(ab)c> je sekvenční vzor

SPADE algoritmus

- SPADE (Sequential Pattern Discovery using Equivalent class)
- Založeno na Apriori principu a generování kandidátů
- Využívá vertikální transformace databáze
- Databáze sekvencí je transformována do velké množiny položek <SID, EID> (<sequence_id, element_id>)

SID	Sekvence
1	<a(abc)(ac)d(cf)>
2	<(ad)c(bc)(ae)>
3	<(ef)(ab)(df)cb>
4	<eg(af)cbc>

SID	EID	Items
1	1	a
1	2	abc
1	3	ac
1	4	d
1	5	cf
2	1	ad
2	2	c
2	3	bc
2	4	ae
3	1	ef
3	2	ab
3	3	df
3	4	c
3	5	b
4	1	e
4	2	g
4	3	af
4	4	c
4	5	b
4	6	c

https://faculty.cc.gatech.edu/~hic/CS7616/pdf/lecture13.pdf

SPADE algoritmus

minsup = 2

SID	EID	Items
1	1	a
1	2	abc
1	3	ac
1	4	d
1	5	cf
2	1	ad
2	2	c
2	3	bc
2	4	ae
3	1	ef
3	2	ab
3	3	df
3	4	c
3	5	b
4	1	e
4	2	g
4	3	af
4	4	c
4	5	b
4	6	c

a		b		...
SID	EID	SID	EID	...
1	1	1	2	
1	2	2	3	
1	3	3	2	
2	1	3	5	
2	4	4	5	
3	2			
4	3			

- Pro nalezení sekvencí **ab** je potřeba, aby **EID(a)** bylo v dané sekvenci **SID** menší než **EID(b)** = prvek **a** byl před **b**

ab			ba			...
SID	EID (a)	EID(b)	SID	EID (b)	EID(a)	...
1	1	2	1	2	3	
2	1	3	2	3	4	
3	2	5				
4	3	5				

aba			...
SID	EID (a)	EID(b)	EID(a)	...
1	1	2	3	
2	1	3	4	

https://faculty.cc.gatech.edu/~hic/CS7616/pdf/lecture13.pdf

Užitečná literatura / kurzy

- Coursera Data Mining specializace
- Těžení sekvenčních vzorů
- Sequential Pattern Mining: Approaches and Algorithms